

Quem vai ganhar?

Predição de resultados no **Campeonato Brasileiro** de futebol — probabilidades calculadas antes do apito.

9.138

partidas

22

temporadas

2

modelos preditivos

ALUNOS

Enzo Nonato · Hugo Eduardo

PROFESSOR

Mateus Silva

Quem vai ganhar? Prevendo o Brasileirão antes do apito

Modelos de probabilidade para clubes e portais esportivos — usando apenas o que se sabe **antes da bola rolar**.

CLIENTE HIPOTÉTICO

Departamentos de análise de desempenho de clubes e portais esportivos

RESTRIÇÃO CRÍTICA

Toda previsão é feita **antes da partida começar**, usando só o histórico dos times.

DECISÕES SUPORTADAS

- Probabilidade de vitória do mandante, empate ou vitória do visitante
- Risco de a partida ter cartão vermelho — impacta escalação e plano tático

POR QUE É DIFÍCIL

Lesões, arbitragem e clima não são capturáveis. O objetivo é **superar o acaso** — não ser perfeito.

De 9.138 partidas a **features sem vazamento**

9.138

partidas × 31 colunas

22

temporadas · 2003–2025

24

features · 12 stats × 2 times

2

alvos · resultado + cartão

★ ANTI-LEAKAGE — O CORAÇÃO DO PIPELINE

Problema

Usar posse e chutes reais do jogo é trapaça — só existem depois do apito.

Solução

Cada feature é a **média das últimas 5 partidas**, calculada antes do jogo.

```
shift(1) + rolling(5)
```

DIVISÃO TREINO / TESTE


Corte cronológico **80 / 20** — out-of-time, nunca aleatório.

ACHADO DE QUALIDADE

Cartão vermelho só registrado a partir de **2015**. Modelo de cartão restrito às **3.798 partidas** com dado real.


O mandante vence quase metade das partidas

A maior vantagem estrutural que o modelo pode explorar — e a razão do baseline ser "chutar sempre mandante".



O peso do mando muda de clube para clube

Do topo (~58%) à base (~29%) de vitórias em casa — esse histórico alimenta as features de cada time.



Recorte: clubes com ≥ 50 jogos como mandante

Como cada modelo decide quem ganha

Quatro famílias de algoritmos disputam a vaga — os mesmos candidatos nos dois modelos.

Logistic Regression

o mais simples

Traça uma **linha reta** separando os grupos: chuta mais e sofre menos gols → provavelmente ganha. Tudo vira uma equação com pesos.

★ Random Forest

o vencedor • 200
árvores

200 árvores de decisão, cada uma com dados aleatórios diferentes. Cada árvore vota e ganha a maioria — como ouvir **200 analistas**.

Gradient Boosting

aprende com os erros

Começa fraco e melhora **em cima dos próprios erros**: cada árvore corrige o que a anterior errou. Devagar, focado nos casos difíceis.

XGBoost

boosting turbinado

A mesma ideia de corrigir erros em sequência, mas **muito mais rápida** — a queridinha das competições. O **tuned** é mais conservador para não decorar o treino.

GRID SEARCH Todos os 5 passaram por busca automática de hiperparâmetros com **validação cruzada temporal (TimeSeriesSplit)** — o código testou várias combinações e ficou com a que deu melhor resultado.

Modelo 1 — Resultado da partida

5 modelos · Grid Search com **TimeSeriesSplit (5 folds)** · métrica principal **F1-macro** (3 classes com peso igual)

MODELO	F1-MACRO	ACURÁCIA	HIPERPARÂMETROS
★ Random Forest	0,377	0,415	n_est=200 · depth=10
Logistic Regression	0,355	0,355	C = 10,0
XGBoost (default)	0,345	0,403	n_est=200 · depth=6
XGBoost (tuned)	0,343	0,437	n_est=300 · lr=0,05
Gradient Boosting	0,276	0,294	n_est=200 · depth=4

BASELINE Chutar sempre mandante → F1-macro ≈ **0,26**. Todos os modelos superam o acaso.

LEITURA DE NEGÓCIO

41%

de acurácia — o teto de previsibilidade do futebol é alto.

O valor está em entregar **probabilidades**, não só "quem ganha" — decisões ponderadas pelo risco.

Modelo 2 — Risco de cartão vermelho

3 modelos · dataset restrito ao dado real · métrica principal **AUC-PR** (correta para eventos raros) · prevalência **21,3%**

MODELO	AUC-PR	ROC-AUC	BRIER ↓
★ Random Forest	0,243	0,543	0,168
Logistic Regression	0,228	0,528	0,235
XGBoost	0,224	0,540	0,202

BASELINE Chute pela prevalência → AUC-PR = **0,213**. Random Forest fica **acima**.


BRIER ↓ Mede a calibração da probabilidade — quanto menor, mais confiável o número. RF tem o menor: **0,168**.

INTERPRETAÇÃO HONESTA

Ganho modesto sobre o baseline é um **resultado real**.

Arbitragem, rivalidade e clima não estão nos dados. Preferimos um **número honesto** a um número inflado.

Do modelo treinado à **previsão em produção**



MLFLOW

8 experimentos versionados (5 resultado + 3 cartão) — acima do mínimo de 5.

FASTAPI

/predict recebe times + features rolantes e devolve resultado, probabilidades e risco de cartão.

DOCKER

docker compose up sobe API (8000) e MLflow UI (5000) em qualquer máquina.

EVIDENTLY

Monitora **data drift** — detecta quando os dados mudam e o modelo pode estar desatualizado.

EXEMPLO DE RESPOSTA · /PREDICT

```
{
  "resultado_previsto": "mandante",
  "probabilidades": {
    "mandante": 0.52,
    "empate": 0.27,
    "visitante": 0.21
  },
  "prob_cartao_vermelho": 0.09,
  "interpretacao": "Favorito: Flamengo (52%)"
}
```

- CONCLUSÃO

Melhor que o acaso — e **honesto** sobre o limite

Da pergunta de negócio à API em produção, sem vazamento de dados e com números que merecem confiança.

PROBLEMA

Prever resultado e risco de cartão **antes do apito**, só com histórico.

SOLUÇÃO

Features de **média móvel sem leakage** e corte cronológico de treino/teste.

RESULTADO

Random Forest venceu os dois modelos — e supera o baseline em ambos.

IMPACTO

Probabilidades, não palpites — decisões ponderadas pelo risco, em produção.

Não buscamos prever o futebol perfeitamente — buscamos **superar o acaso de forma transparente**.

[github](#) · [projeto-av2-data_science](#) · [v1.0](#)

Enzo Nonato & Hugo Eduardo · Prof. Mateus Silva