



Autarquia Educacional do Vale do São Francisco
Faculdade de Ciências Aplicadas e Sociais de Petrolina
Curso de Ciência da Computação

Predição de Resultados e Ocorrência de Cartão Vermelho no Campeonato Brasileiro Utilizando Machine Learning

Alunos: Hugo Eduardo Dos Santos Rego

Enzo Nonato Da Silva Souza

Professor: Matheus Amorim Silva

Disciplina: Ciencia de dados

SUMÁRIO

1. INTRODUÇÃO	2
2. DADOS	2
2.1. Fonte dos Dados	2
2.2. Variáveis Utilizadas	3
2.3. Análise Exploratória dos Dados	3
3. METODOLOGIA	4
3.1. Pipeline de Preparação dos Dados	4
3.2. Engenharia de Atributos	5
3.3. Modelagem	5
3.4. Estratégia de Validação	6
3.5. Monitoramento e Detecção de Drift	6
4. RESULTADOS	6
4.1. Predição de Resultado da Partida	6
4.2. Predição de Cartão Vermelho	7
4.3. Análise de Erros	7
5. CONCLUSÃO	8

1. INTRODUÇÃO

O futebol é um dos esportes mais populares do mundo e movimenta uma grande quantidade de informações estatísticas a cada partida. Clubes, analistas esportivos, casas de apostas e plataformas de dados utilizam essas informações para compreender padrões de desempenho e apoiar processos de tomada de decisão. Nesse contexto, técnicas de Ciência de Dados e Aprendizado de Máquina têm sido cada vez mais empregadas para transformar dados históricos em previsões úteis.

O Campeonato Brasileiro é uma competição de longa duração, composta por diversas equipes e milhares de partidas registradas ao longo dos anos. A existência desse grande volume de dados possibilita a construção de modelos capazes de identificar tendências relacionadas ao desempenho das equipes e aos eventos ocorridos durante os jogos.

O problema abordado neste trabalho consiste em prever dois eventos distintos antes da realização de uma partida: o resultado final do jogo (vitória do mandante, empate ou vitória do visitante) e a ocorrência de pelo menos um cartão vermelho durante a partida. Essas previsões podem auxiliar departamentos de análise de desempenho, profissionais do esporte e plataformas especializadas na elaboração de estratégias e avaliações pré-jogo.

O objetivo do projeto é desenvolver um sistema de Machine Learning capaz de realizar essas previsões utilizando exclusivamente informações históricas disponíveis antes do início das partidas, evitando vazamento de informação (data leakage) e garantindo que os modelos operem em um cenário próximo ao mundo real.

1. DADOS

2.1 Fonte dos Dados

Os dados utilizados foram obtidos a partir do dataset do Campeonato Brasileiro disponível no Kaggle, publicado por Adao Duque.

Foram utilizados três arquivos principais:

- campeonato-brasileiro-full.csv
- campeonato-brasileiro-estatisticas-full.csv
- campeonato-brasileiro-cartoes.csv

O período coberto pelos dados compreende as temporadas entre 2003 e 2025.

Após o processo de preparação e engenharia de atributos, o conjunto final passou a conter aproximadamente 9.138 partidas e 31 colunas.

2.1 Fonte dos Dados

O projeto utiliza duas variáveis-alvo:

Resultado da partida

- Mandante
- Empate
- Visitante

Cartão vermelho

- 0 = não ocorreu cartão vermelho
- 1 = ocorreu pelo menos um cartão vermelho

As variáveis explicativas foram construídas a partir das médias móveis das últimas cinco partidas de cada equipe.

Entre as estatísticas utilizadas estão:

- Chutes
- Chutes no alvo
- Posse de bola
- Passes
- Precisão dos passes
- Faltas
- Cartões amarelos
- Impedimentos
- Escanteios
- Gols marcados
- Gols sofridos

Cada atributo é calculado separadamente para mandante e visitante.

2.3 Análise Exploratória dos Dados

A distribuição dos resultados mostrou forte vantagem do fator casa:

- Vitória do mandante: 49,7%
- Empate: 26,3%
- Vitória do visitante: 24,0%

Esse comportamento é consistente com a literatura esportiva, que aponta a influência do mando de campo sobre o desempenho das equipes.

Em relação aos cartões vermelhos, aproximadamente 8,6% das partidas apresentaram pelo menos uma expulsão considerando todo o conjunto de dados. Entretanto, observou-se que os registros desse evento só se tornam consistentes a partir de 2015, o que justificou a restrição temporal utilizada no treinamento do modelo de cartões.

A análise temporal mostrou que a taxa de vitórias do mandante permanece relativamente estável ao longo das temporadas, variando geralmente entre 45% e 55%.

A matriz de correlação revelou forte associação entre variáveis ofensivas, como chutes, passes e escanteios, indicando que equipes com maior volume ofensivo tendem a apresentar desempenho estatístico semelhante nessas métricas.

3. Metodologia

3.1 Pipeline de Preparação dos Dados

O pipeline foi implementado utilizando a biblioteca Scikit-Learn.

As etapas principais foram:

1. Coleta dos dados via KaggleHub.
2. Limpeza e padronização das variáveis.
3. Conversão de estatísticas percentuais para valores numéricos.
4. Construção das médias rolantes das últimas cinco partidas.
5. Geração dos targets.
6. Imputação de valores ausentes pela mediana.
7. Padronização das variáveis numéricas utilizando StandardScaler.

3.2 Engenharia de Atributos

A principal estratégia de engenharia de atributos consistiu na utilização de médias móveis históricas.

Para cada clube, foi calculada a média das últimas cinco partidas anteriores ao jogo atual. O código aplica:

- `shift(1)` para remover a partida atual da janela.
- `rolling(window=5)` para calcular a média histórica.

Essa abordagem elimina o risco de vazamento de informação, garantindo que apenas dados disponíveis antes da partida sejam utilizados na previsão.

3.3 Modelagem

Foram desenvolvidos dois problemas independentes.

Problema 1 – Resultado da Partida

Classificação multiclasse com três categorias:

- Vitória do mandante
- Empate
- Vitória do visitante

Modelos avaliados:

- Logistic Regression
- Random Forest
- Gradient Boosting
- XGBoost padrão
- XGBoost otimizado

Problema 2 – Cartão Vermelho

Classificação binária.

Modelos avaliados:

- Logistic Regression
- Random Forest
- XGBoost

3.4 Estratégia de Validação

Por se tratar de séries temporais, foi utilizada uma abordagem que respeita a ordem cronológica dos dados.

O conjunto foi dividido em:

- 80% das partidas mais antigas para treinamento
- 20% das partidas mais recentes para teste

Além disso, durante a busca de hiperparâmetros foi utilizado:

- TimeSeriesSplit com 5 folds

Essa estratégia evita que informações futuras influenciem o treinamento.

3.5 Monitoramento e Drift

O projeto inclui uma etapa de monitoramento utilizando a biblioteca Evidently AI.

Foram gerados relatórios de:

- Data Drift
- Mudanças de distribuição das variáveis
- Comparação entre períodos históricos e recentes

Esse mecanismo permite identificar quando os modelos podem necessitar de retreinamento.

4. RESULTADOS

4.1 Predição de Resultado da Partida

Os resultados obtidos foram:

Modelo	F1-Macro	Acurácia
Random Forest	0,3767	0,4147
Logistic Regression	0,3548	0,355
XGBoost	0,3453	0,4026
XGBoost Tunado	0,3428	0,4365
Gradient Boosting	0,2763	0,2943

O Random Forest apresentou o melhor equilíbrio entre as classes, alcançando o maior valor de F1-Macro.

Embora a acurácia pareça relativamente baixa, o problema possui elevada imprevisibilidade devido à natureza do futebol. Ainda assim, todos os modelos superaram o baseline de sempre prever vitória do mandante.

4.2 Predição de Cartão Vermelho

Resultados:

Modelo	AUC-PR	ROC-AUC
Random Forest	0,2425	0,5428
Logistic Regression	0,2277	0,5279
XGBoost	0,2243	0,5399

O melhor desempenho foi novamente obtido pelo Random Forest.

A dificuldade desse problema decorre do forte desbalanceamento dos dados e do caráter imprevisível das expulsões, frequentemente influenciadas por fatores comportamentais e circunstanciais não representados nas variáveis utilizadas.

4.3 Análise de Erros

A avaliação por temporada demonstrou estabilidade razoável do modelo de resultado ao longo dos anos, sem quedas abruptas de desempenho.

Os principais erros observados ocorreram em partidas equilibradas, nas quais pequenas diferenças estatísticas entre os clubes dificultavam a separação entre vitória, empate e derrota.

Para o problema de cartão vermelho, a baixa prevalência do evento limitou a capacidade de generalização dos modelos, tornando a previsão mais desafiadora.

5. CONCLUSÃO

Este trabalho apresentou um sistema de Machine Learning para previsão de resultados e ocorrência de cartões vermelhos no Campeonato Brasileiro utilizando dados históricos entre 2003 e 2025.

A metodologia adotada priorizou a prevenção de vazamento de informação por meio da utilização de médias rolantes calculadas exclusivamente com partidas anteriores. Além disso, a validação temporal garantiu uma avaliação mais próxima do cenário real de utilização.

Os resultados demonstraram que o modelo Random Forest apresentou o melhor desempenho para ambos os problemas analisados. Embora as métricas obtidas não sejam extremamente elevadas, elas refletem a complexidade inerente ao futebol e superaram abordagens baselines simples.

Como trabalhos futuros, podem ser incorporadas novas fontes de informação, como escalações, desempenho individual dos atletas, lesões, valor de mercado das equipes, estatísticas avançadas e dados contextuais das partidas. Essas informações têm potencial para aumentar significativamente a capacidade preditiva dos modelos desenvolvidos.

6. REFERÊNCIAS

<https://www.kaggle.com/datasets/adaoduke/campeonato-brasileiro-de-futebol>